Classification d'émotions dans des tweets COVID-19

Prétraitement, lemmatisation et régression logistique

Kaufmann Raphaël

Juin 2026

Table des matières

1 Introduction **2**

2 Prétraitement des tweets **2**
2.1 Données source . . . 2
2.2 Filtrage des mots courants (liste-vide) . . . 2
2.3 Features émotionnelles extraites . . . 2
2.4 Conservation des émojis . . . 2

3 Lemmatisation **3**
3.1 Principe . . . 3
3.2 Exception : mots d'emphase émotionnelle . . . 3
3.3 Format de sortie . . . 3

4 Classification par régression logistique **3**
4.1 Construction des features . . . 3
4.2 Modèle . . . 3
4.3 Première expérience : 193 tweets étiquetés manuellement . . . 4
4.4 Étiquetage automatique : passage à 3 000 tweets . . . 4
4.5 Deuxième expérience : 3 000 tweets auto-étiquetés . . . 4

5 Conclusion et pistes d'amélioration **5**

1 Introduction

Ce document récapitule les étapes réalisées pour construire un pipeline de classification d'émotions appliqué à des tweets relatifs au COVID-19. L'objectif est d'associer à chaque tweet l'une des sept émotions suivantes : **neutral, disgust, happiness, anger, surprise, sadness, fear**.

Le pipeline se décompose en trois grandes phases :

1. **Prétraitement et filtrage** – nettoyage du texte et extraction de features émotionnelles ;
2. **Lemmatisation** – réduction des mots à leur forme canonique, avec exceptions pour les mots d'emphase ;
3. **Classification par régression logistique** – entraînement et évaluation du modèle.

2 Prétraitement des tweets

2.1 Données source

Le dataset initial est `covid19_tweets.csv`, contenant environ 179 000 tweets. La colonne d'intérêt est `text`. Un premier nettoyage effectué dans `indexation.py` supprime les URLs à l'aide d'une expression régulière :

```
motif_lien = r"https?://\S+"
tweet_nettoye = re.sub(motif_lien, '', tweet)
```

2.2 Filtrage des mots courants (liste-vide)

Le filtrage est réalisé dans `lemmatisation.py` via le modèle spaCy `en_core_web_sm`. Trois règles guident la conservation d'un token :

1. **Mot utile** : le token n'appartient pas à la liste-vide spaCy (326 stop-words anglais).
2. **Négation** : certains stop-words sont explicitement conservés car porteurs de sens émotionnel (colère, peur, tristesse).
3. **Accentuation par répétition consécutive** : un stop-word répété ≥ 2 fois d'affilée (ex. *very very*) est conservé pour signaler une intensité émotionnelle.

Les négations préservées sont :

`not, no, nor, never, nothing, nobody, none, neither, nowhere, n't, cannot, without, most`

2.3 Features émotionnelles extraites

En parallèle du filtrage textuel, trois indicateurs numériques sont calculés **sur le tweet original** (avant mise en minuscules) :

2.4 Conservation des émojis

Les émojis sont détectés via la librairie `emoji` et systématiquement conservés, car ils constituent des marqueurs d'émotion particulièrement explicites (→ colère, → tristesse).

Feature	Description	Signal émotionnel
`pct_majuscules`	% de lettres majuscules	Énervement, intensité
`exclamations`	Nombre de `!`	Colère, surprise, joie forte
`interrogations`	Nombre de `?`	Confusion, incrédulité

TABLE 1 – Features numériques extraites pour la détection d'émotions

3 Lemmatisation

3.1 Principe

La lemmatisation réduit chaque mot à sa forme de base : *running* → *run*, *deaths* → *death*. Elle est appliquée après le filtrage, via le pipeline spaCy avec NER et parser désactivés pour des raisons de performance (`nlp.pipe(..., disable=["ner", "parser"])`).

3.2 Exception : mots d'emphase émotionnelle

Les mots comportant une lettre répétée **3 fois ou plus consécutivement** ne sont **pas lemmatisés**, car cette répétition de lettres est elle-même un signal d'émotion :

WHATTTTT, *heyyyy*, *nooooo*

La détection repose sur l'expression régulière `(.)\1{2,}` : si un caractère apparaît au moins 3 fois de suite, le mot est conservé tel quel.

3.3 Format de sortie

Chaque tweet traité est exporté en chaîne de caractères (mots séparés par des espaces), puis sauvegardé dans `data/tweets_traites.csv` avec les colonnes suivantes :

`tweet_lemmatise ; pct_majuscules ; exclamations ; interrogations`

4 Classification par régression logistique

4.1 Construction des features

Le modèle combine deux familles de features via un `ColumnTransformer` scikit-learn :

— **TF-IDF** sur le texte : unigrammes + bigrammes, 5 000 features max, fréquence minimale de 2 occurrences.

— **Features numériques** : `pct_majuscules`, `exclamations`, `interrogations`, normalisées par `StandardScaler`.

4.2 Modèle

```
LogisticRegression(
    max_iter=1000,
    class_weight="balanced",  # compense le desequilibre des
       classes
    C=1.0,
    random_state=42,
)
```

Le paramètre `class_weight="balanced"` est crucial : il pondère automatiquement les classes sous-représentées pour éviter que *neutral* (majoritaire) écrase les autres.

4.3 Première expérience : 193 tweets étiquetés manuellement

Émotion	Exemples	Précision	Rappel	F1
neutral	111	0.40	0.30	0.34
fear	52	0.56	0.36	0.43
happiness	24	0.00	0.00	0.00
sadness	3	0.00	0.00	0.00
anger	2	0.00	0.00	0.00
disgust	1	0.00	0.00	0.00
Accuracy globale			**28 %**	

TABLE 2 – Résultats avec 193 tweets étiquetés – dataset trop petit et déséquilibré

Les classes avec moins de 5 exemples ne peuvent pas être apprises correctement.

4.4 Étiquetage automatique : passage à 3 000 tweets

Pour pallier le manque de données, un modèle pré-entraîné de HuggingFace a été utilisé pour étiqueter automatiquement 3 000 tweets :

`j-hartmann/emotion-english-distilroberta-base`

Ce modèle, basé sur DistilRoBERTa, détecte 7 émotions alignées avec nos cibles. L'émotion *joy* est remappée vers *happiness*.

4.5 Deuxième expérience : 3 000 tweets auto-étiquetés

L'accuracy passe de **28 %** à **50 %**, soit un gain de 22 points. Les mots les plus prédictifs par émotion confirment la cohérence du modèle :

- **anger** : *protest, blame, hate, refuse, stupidity*
- **fear** : *lockdown, risk, crisis, quarantine, threat*
- **happiness** : *good, happy, thank, great, love*
- **sadness** : *death, miss, suffer, depression, bad*
- **neutral** : *update, mask, case, test, community*

Émotion	Tweets étiquetés
neutral	1613
fear	378
sadness	357
happiness	298
anger	220
surprise	119
disgust	15
Total	**3 000**

TABLE 3 – Répartition des émotions après étiquetage automatique

Émotion	Support	Précision	Rappel	F1
neutral	323	0.76	0.52	0.62
anger	44	0.42	0.57	0.49
fear	76	0.41	0.50	0.45
sadness	71	0.39	0.51	0.44
happiness	59	0.30	0.46	0.36
surprise	24	0.14	0.25	0.18
disgust	3	0.00	0.00	0.00
Accuracy globale		**50 %**		

TABLE 4 – Résultats avec 3 000 tweets – nette amélioration

5 Conclusion et pistes d'amélioration

Le pipeline construit permet de classifier automatiquement les émotions de tweets COVID-19 avec une accuracy de 50 % à partir de 3 000 exemples.

Les principales limites identifiées sont :

— **Déséquilibre persistant** : *disgust* reste quasi absent (15 exemples).

— **Qualité des labels** : l'étiquetage automatique introduit du bruit.

— **Modèle simple** : la régression logistique ne capture pas les relations syntaxiques complexes.

Pistes pour améliorer les performances :

1. Augmenter le dataset à 10 000+ tweets étiquetés.
2. Fine-tuner directement un modèle BERT/RoBERTa sur les tweets COVID.
3. Valider manuellement un sous-ensemble des labels automatiques.