Évaluation de la classification d'émotions de tweets COVID-19

Étiquetage automatique par règles *vs* apprentissage automatique : confrontation à une vérité terrain annotée à la main

Projet EI – Tweets

Juin 2026

Résumé

Ce rapport complète le travail de prétraitement et de lemmatisation en se concentrant sur l'**évaluation** de la classification d'émotions. Les tweets ont été étiquetés *automatiquement* par un système de règles (lexique NRC + émojis), puis un modèle d'apprentissage automatique (régression logistique sur représentation sac-de-mots / TF-IDF) a été entraîné sur ces étiquettes. Nous évaluons les deux approches contre un jeu de **297 tweets annotés manuellement**. Le résultat central est que le modèle reproduit fidèlement les règles (**86 % d'accord**) mais que *ni les règles ni le modèle ne correspondent au jugement humain* : leur accuracy ($\approx$ 23–24 %) est très inférieure à la baseline triviale « toujours *neutral* » (57 %), et le κ de Cohen est quasi nul. Le facteur limitant est donc la *qualité de l'étiquetage automatique*, non l'algorithme d'apprentissage. Une révision des règles (section 6) fait ensuite presque doubler l'accuracy, mais sans gain de κ pour les règles : l'amélioration est surtout mécanique, le ML étant le seul à progresser réellement.

1 Données et représentation

Le jeu de travail (`bdd_etiquetee_emotions.csv`) contient **179 108** tweets nettoyés et lemmatisés. Chaque ligne comporte :

- `tweet_lemmatise` : le texte du tweet (nettoyé, lemmatisé) ;
- trois variables numériques : `pct_majuscules`, `exclamations`, `interrogations` ;
- `emotion` : l'étiquette produite **automatiquement** par les règles (cible d'entraînement) ;
- `Emotion` : l'annotation **manuelle** (vérité terrain), présente sur 297 tweets seulement.

Représentation matricielle. Le texte est transformé en matrice creuse par *sac de mots* puis pondération **TF-IDF** (unigrammes + bigrammes, `min_df=2`, `max_features=5000`). Les trois variables numériques sont centrées-réduites (*StandardScaler*) puis concaténées à la matrice TF-IDF. C'est cette matrice qui alimente le classifieur.

Déséquilibre des classes. La figure 1 montre que les deux étiquetages sont dominés par les classes *neutral* et *anticipation*, les émotions *joy* et *surprise* étant rares. Ce déséquilibre est traité par l'option `class_weight="balanced"` de la régression logistique.

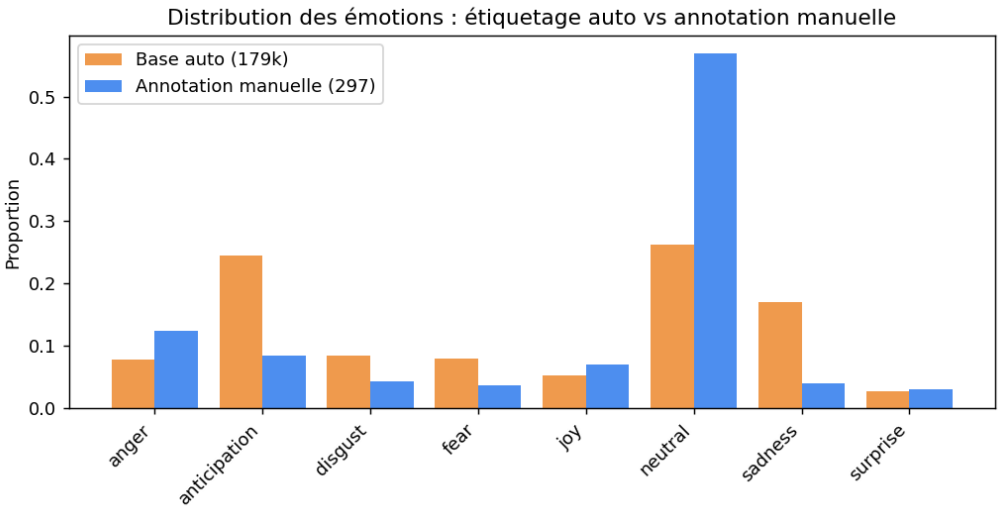


FIGURE 1 – Distribution des émotions : étiquetage automatique (179k tweets) *vs* annotation manuelle (297 tweets).

2 Modèle d'apprentissage

Le modèle est une **régression logistique** multinomiale (`scikit-learn`), choisie pour sa robustesse en grande dimension et son *interprétabilité* (on peut lire les mots les plus prédictifs via les coefficients). Hyperparamètres : `C=1.0`, `max_iter=1000`, `class_weight="balanced"`. La chaîne complète (TF-IDF + numériques + classifieur) est encapsulée dans un *Pipeline* scikit-learn.

Protocole d'évaluation honnête. Pour éviter toute fuite de données, le modèle est entraîné sur les **178 811** tweets *non annotés à la main* (en utilisant les étiquettes automatiques comme cible), puis testé sur les **297** tweets annotés manuellement, qui n'ont jamais été vus à l'entraînement. On compare alors, sur ce même jeu de référence :

(A) les prédictions du **ML** *vs* l'annotation manuelle ;

(B) les étiquettes des **règles automatiques** *vs* l'annotation manuelle.

3 Résultats

Prédicteur	**Accuracy**	**κ de Cohen**
Baseline « toujours *neutral* »	0,569	—
Règles automatiques *vs* manuel	0,226	0,057
Machine learning *vs* manuel	0,239	0,038
Accord ML $\leftrightarrow$ règles auto : 0,859		

TABLE 1 – Performances contre la vérité terrain (297 tweets annotés à la main). Le κ de Cohen mesure l'accord corrigé du hasard (0 = hasard, 1 = parfait).

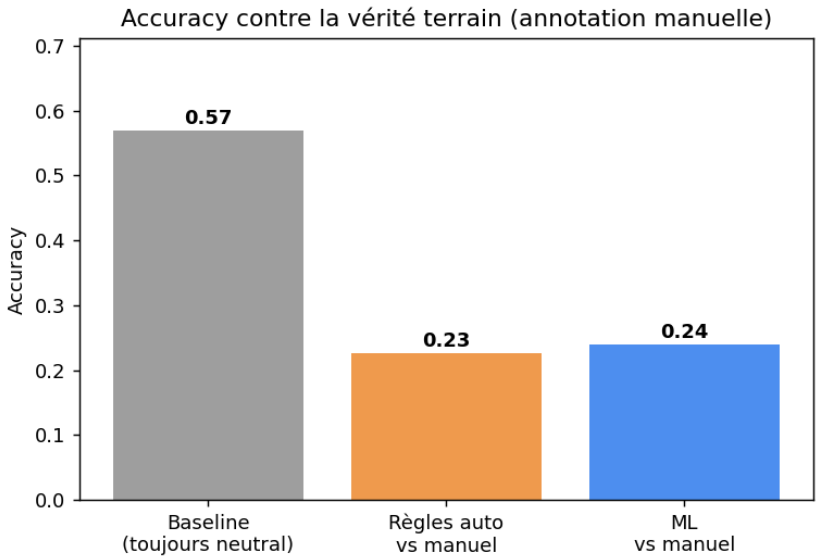


FIGURE 2 – Accuracy des deux approches comparée à la baseline triviale. Les deux sont *très en dessous* du « toujours *neutral* ».

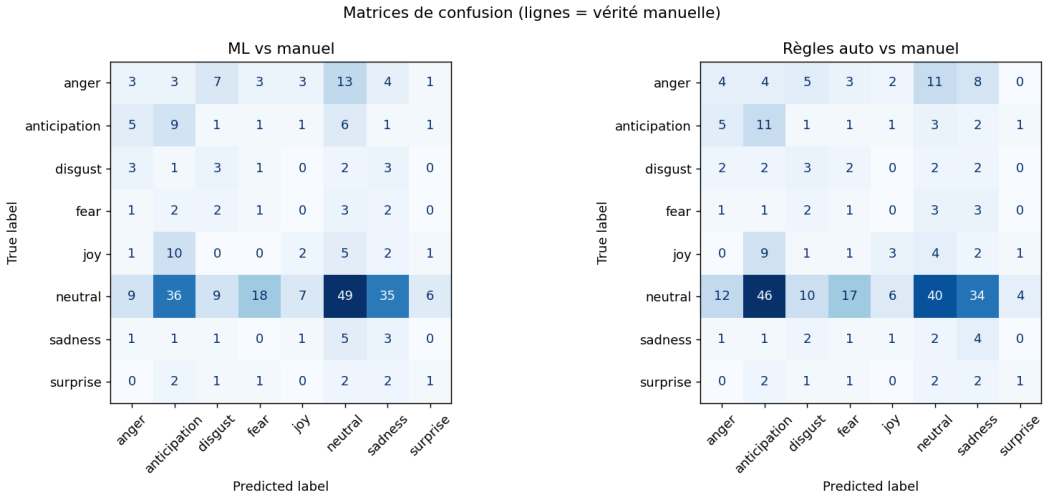


FIGURE 3 – Matrices de confusion sur les 297 tweets annotés (lignes = vérité manuelle, colonnes = prédiction). À gauche le ML, à droite les règles automatiques. Les deux dispersent fortement la classe majoritaire *neutral*.

4 Interprétation

1. **Le score élevé obtenu en validation interne était trompeur.** Évalué contre ses *propres* étiquettes automatiques, le modèle atteignait $\approx 0,86$ d'accuracy. Mais ce chiffre ne mesure que sa *fidélité aux règles* : l'accord ML↔règles est en effet de $0,859$ (table 1), cohérent avec ce $0,86$.
2. **Contre la vérité humaine, les deux approches échouent.** Avec $\approx$ 23–24 % d'accuracy, règles et modèle font *moins bien qu'un classifieur trivial* prédisant toujours *neutral* (57 %). Le κ de Cohen, quasi nul ($\leq 0,06$), confirme un accord à peine supérieur au hasard.
3. **Le ML hérite des défauts de son étiquetage.** Comme il apprend à reproduire les

règles (86 % d'accord), il ne peut pas les dépasser : *garbage in, garbage out*. Le problème ne vient donc pas de l'algorithme d'apprentissage mais de la *validité de l'étiquetage automatique*, qui s'écarte fortement du jugement humain.

Limites. Le jeu de référence ne compte que 297 tweets, fortement déséquilibrés (*surprise* = 9, *fear* = 11), ce qui rend les métriques par classe bruitées. Par ailleurs, l'option `balanced` pénalise l'accuracy brute sur ce jeu majoritairement neutre, mais ne change pas la conclusion qualitative.

5 Conclusion et perspectives

L'étiquetage automatique par règles, bien que reproductible et peu coûteux, ne reflète pas fidèlement les émotions perçues par un annotateur humain ($\approx 23\,\%$ d'accord, $\kappa \approx 0,06$). Un modèle de régression logistique entraîné sur ces étiquettes les imite très bien (86 %) mais hérite donc de leur faible validité. **Améliorer le système passe d'abord par améliorer la qualité des étiquettes** : raffiner les règles, ou — préférablement — constituer un jeu d'entraînement annoté à la main de taille suffisante et entraîner directement le modèle dessus. Augmenter la complexité du modèle, à étiquetage constant, serait sans effet.

Pistes concrètes.

- Étendre l'annotation manuelle (quelques milliers de tweets) et entraîner/évaluer le modèle directement dessus (validation croisée).
- Comparer plusieurs classifieurs (SVM linéaire, Naïve Bayes) et calibrer le seuil de la classe *neutral*.
- Auditer les règles d'étiquetage classe par classe à partir des matrices de confusion (figure 3).

6 Amélioration de l'étiquetage : comparaison avant/après

À la suite de cette analyse, les règles d'étiquetage ont été révisées. La principale modification est l'introduction d'une règle « *neutral* par défaut » : une émotion n'est attribuée que si son score dépasse un seuil et domine nettement les autres ; le vocabulaire COVID factuel (*case*, *death*, *test*, *positive*...) est par ailleurs neutralisé. La nouvelle base (`bdd_etiquetee_new.csv`) classe ainsi 116 791 tweets en *neutral* contre 47 123 auparavant. Le protocole d'évaluation est identique (entraînement hors des 297 tweets annotés, test sur ceux-ci).

Indicateur	Ancien	Nouveau	Évol.
Règles — accuracy	0,226	**0,444**	+0,22
Règles — κ	0,057	0,054	$\approx$ stable
ML — accuracy	0,239	**0,354**	+0,12
ML — κ	0,038	**0,094**	+0,06
Accord ML $\leftrightarrow$ règles	0,859	0,660	—
Baseline « toujours neutral » : 0,569			

TABLE 2 – Indicateurs avant/après révision des règles, contre la vérité terrain (297 tweets annotés).

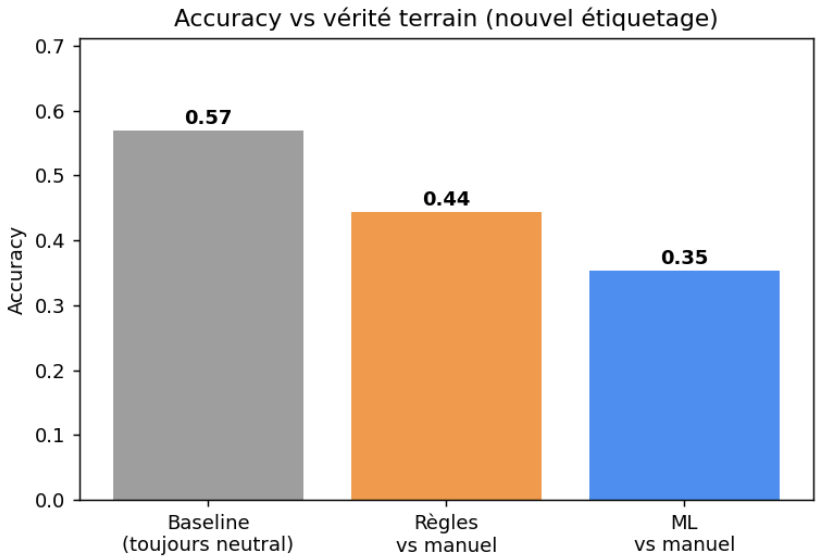


FIGURE 4 – Accuracy après révision des règles. Le gain est réel mais l'accuracy des règles reste sous la baseline triviale.

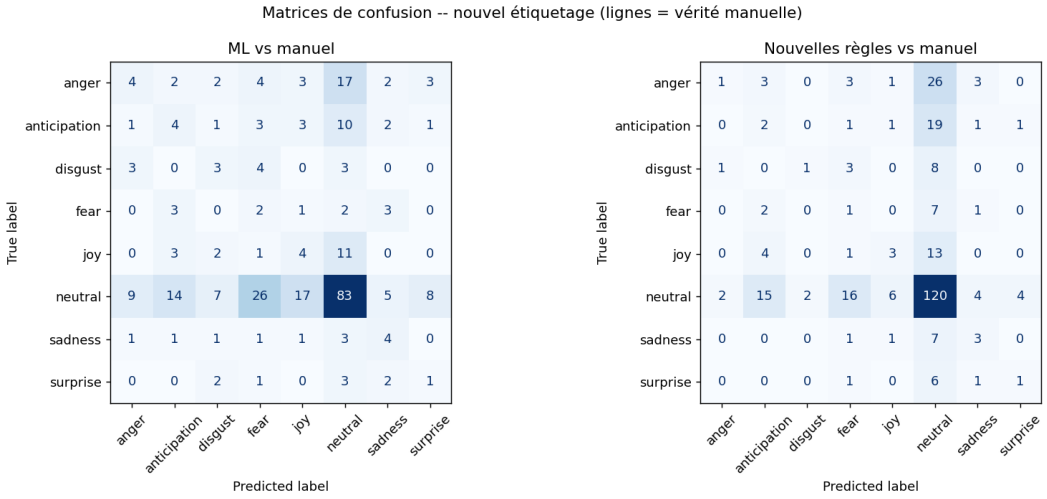


FIGURE 5 – Matrices de confusion après révision (lignes = vérité manuelle). La classe *neutral* est désormais bien mieux récupérée.

Analyse. L'accuracy des règles a presque **doublé** (0,226 → 0,444) : la règle « *neutral* par défaut » réduit efficacement le sur-classement des tweets factuels. **Cependant**, le κ de Cohen reste *plat* (0,057 → 0,054). Contrairement à l'accuracy, le κ corrige du hasard : ce gain d'accuracy est donc en grande partie *mécanique*, dû au fait que les règles prédisent plus souvent la classe majoritaire *neutral* (57 % du jeu de test). En accuracy pure, les règles (0,444) restent d'ailleurs *en dessous* de la baseline « toujours *neutral* » (0,569).

En revanche, le modèle de ML progresse réellement sur le κ (0,038 → 0,094, soit $\times 2,5$) : c'est le seul indicateur traduisant une amélioration *authentique* de la discrimination entre émotions, même si elle demeure modeste. La baisse de l'accord ML↔règles (0,859 → 0,660) confirme que le ML ne se contente plus de recopier les règles.

Conséquence. Les nouvelles règles réduisent le bruit (moins de fausses émotions), ce qui bénéficie au ML, mais le font surtout en « jouant la sécurité » sur *neutral*. Le prochain levier est de mieux *discriminer les émotions entre elles* (règles ciblées par émotion : *anger*, *fear*, *joy*...), seul moyen de faire progresser le κ.

A Reproductibilité

- `machine_learning.py` : modèle de référence (jeu annoté à la main).
- `machine_learning_auto.py` : modèle entraîné sur l'étiquetage automatique, test sur les 50 000 derniers tweets.
- `evaluation_ml.py` : comparaison ML *vs* règles contre la vérité manuelle (rapports détaillés par classe).
- `rapport_figures.py` : génération des figures et métriques de la section principale.
- `evaluation_new.py` : reprise des mêmes indicateurs sur le nouvel étiquetage (`bdd_etiquetee_new.csv`), figures `*_new.png` de la section 6.

Environnement : Python 3.10, scikit-learn 1.7, pandas 2.3, matplotlib 3.10.